

T.C.  
İZMİR KÂTİP ÇELEBİ ÜNİVERSİTESİ  
YZM536 Veri Mühendisliği ve Uygulamaları

## İlerleme Raporu

Proje:

Gerçek Zamanlı Hava Kalitesi İzleme — Uçtan Uca Veri Boru Hattı (İzmir Vakası)

Y250234065

EMRE YILMAZ

Ders Yürütücüsü: Dr. Öğr. Üyesi GÖZDE ÇAY

Gönderme Tarihi: 29 Nisan 2026

# İçindekiler

|                                                       |           |
|-------------------------------------------------------|-----------|
| <b>Bölüm 1: Özet</b>                                  | <b>3</b>  |
| 1A. Proje Özeti                                       | 3         |
| 1B. Projenin Amacı                                    | 3         |
| <b>Bölüm 2: Giriş ve Arka Plan</b>                    | <b>4</b>  |
| 2A. Problem Tanımı                                    | 4         |
| 2B. Problem İçin Bulunan Çözüm                        | 5         |
| 2C. Bu Alanda Yapılan Daha Önceki Çalışmaların Özeti  | 5         |
| <b>Bölüm 3: Veri Seti ve Modelleme</b>                | <b>7</b>  |
| 3A. Projede Kullanılan Veri Setleri                   | 7         |
| 3B. Veri Toplama Aşamaları                            | 8         |
| 3C. Veri Formatları ve Yöntemler                      | 9         |
| 3D. Veri Ön İşleme                                    | 9         |
| 3E. Kullanılan Veri Modelleri ve Veri Diyagramı       | 10        |
| 3F. Kullanılan Analizler ve Hesaplamalar              | 11        |
| 3G. Makine Öğrenmesi Yöntemleri                       | 12        |
| 3H. Görselleştirme                                    | 12        |
| 3I. Kullanılan Veritabanları                          | 12        |
| <b>Bölüm 4: İlerleme</b>                              | <b>13</b> |
| 4A. Proje Öneri Formunda Belirtilen Aşamaların Detayı | 13        |
| 4B. Yüksek Seviyeli Sistem Mimarisi                   | 14        |
| 4C. Performans Ölçümleri (Sprint 4 DoD Doğrulaması)   | 14        |
| 4D. Test ve Coverage Durumu                           | 15        |
| 4E. Karşılaşılan Problemler ve Çözümler               | 16        |
| 4F. Çözülemeyen Problemler ve Planlanan Yaklaşımlar   | 17        |
| <b>Bölüm 5: Sonraki Aşamalar</b>                      | <b>18</b> |
| 5A. Dönem Sonuna Kadar Yapılacak İşlemler             | 18        |
| 5B. Plan Görseli                                      | 18        |
| 5C. Hafta 8 Final Teslim Öncesi Tamamlanacak Maddeler | 19        |
| 5D. Risk Yönetimi                                     | 19        |
| <b>Kaynakça</b>                                       | <b>20</b> |

## Bölüm 1: Özet

### 1A. Proje Özeti

Bu proje, İzmir metropolünde altı sabit istasyondan toplanan gerçek zamanlı ve tarihsel hava kalitesi verilerini, modern veri mühendisliği yığını üzerinde uçtan uca işleyen ve operatör panellerine sunan bir veri boru hattı (data pipeline) tasarımını ele almaktadır. Çalışma; mesaj kuyruğu (Apache Kafka), akış işleme (Apache Spark Structured Streaming), boyutsal modelleme (PostgreSQL 16 yıldız şeması) ve görselleştirme (Grafana, Streamlit) bileşenlerini birlikte kullanarak dersin teorik kapsamını gerçek bir kullanım senaryosu üzerinde uygulamayı amaçlar.

Sistem iki farklı kanaldan veri tüketmektedir: (i) OpenWeatherMap Air Pollution API'sinden saatlik canlı çekim ile beslenen streaming kanalı ve (ii) T.C. Çevre, Şehircilik ve İklim Değişikliği Bakanlığı Sürekli İzleme Merkezi (SİM) portalından sağlanan tarihsel CSV dosyalarının batch yüklemesi. Her iki kanal ortak bir fact tablosunda buluşur; sunum katmanı bu tablo üzerinde kurulu materialize edilmiş görünümüleri okur.

Mimari, hibrit bir dağıtım deseniyle çalışmaktadır: Stateful streaming katmanı (Spark master ve worker, Kafka brokeri) yerel Docker Compose ortamında tutulurken; PostgreSQL, Grafana ve birkaç stateless Python uygulaması Coolify üzerinde managed kaynak olarak provision edilmektedir. Bu ayırım, hem geliştirici döngüsünün hızını korur hem de bulut tabanlı dağıtım deseninin ders kapsamına alınmasını sağlar.

### 1B. Projenin Amacı

Çalışmanın akademik amacı, dersin kapsadığı dört temel başlığı (mesaj kuyruğu, akış işleme, ilişkisel veri ambarı modellemesi ve görselleştirme) somut bir kullanım senaryosu üzerinde bütünlüklü biçimde uygulamaktır. Mühendislik amacı ise operasyonel olarak ayağa kaldırılabilir, yeniden çalıştırılabilir (idempotent) ve gözlemlenebilir (observable) bir referans pipeline ortaya çıkarmaktır.

Spesifik hedefler şunlardır: (1) Saatlik granülerite ile 6 istasyon × 6 kirletici (PM<sub>2.5</sub>, PM<sub>10</sub>, NO<sub>2</sub>, SO<sub>2</sub>, O<sub>3</sub>, CO) için yıllık ~315.000 satıra ulaşan ölçüm hacmini 60 saniyenin altında veritabanına yükleyebilen bir batch loader; (2) Aynı CSV iki kez yüklendiğinde ek satır üretmeyen, yapısal seviyede idempotent bir ingestion akışı; (3) Aylık RANGE partition + BRIN indeks kombinasyonu ile zaman serisi sorgularında partition pruning kazancını ölçülebilir biçimde gösteren bir veritabanı tasarımı; (4) Hafta 7 sonunda Spark Structured Streaming ile 10 dakikalık watermark ve 1 saatlik tumbling window üzerinden anlık AQI (Air Quality Index) hesaplayan bir streaming işi; (5) Hafta 13 sonunda Grafana ve Streamlit panelleriyle hem operasyonel izleme hem analitik keşif için sunum katmanı.

## Bölüm 2: Giriş ve Arka Plan

### 2A. Problem Tanımı

Türkiye İstatistik Kurumu ve Çevre, Şehircilik ve İklim Değişikliği Bakanlığı verilerine göre İzmir, parçacık çapı 2,5 mikrometrenin altındaki toz ( $PM_{2.5}$ ) yıllık ortalamalarında Dünya Sağlık Örgütü'nün 2021 güncellenmiş kılavuzunda belirlediği  $5 \mu g/m^3$  sınırını sürekli olarak aşmaktadır. Avrupa Birliği'nin 2008/50/EC numaralı Hava Kalitesi Direktifi'nin koyduğu  $25 \mu g/m^3$  yıllık sınırın da bazı dönemlerde aşıldığı raporlanmıştır. İzmir'in topografik özellikleri (İzmir Körfezi etrafında toplanmış yerleşim, Aliağa endüstri bölgesi, sınırlı doğal hava sirkülasyonu) hava kirliliğinin lokal pikler oluşturmaya neden olmaktadır.

Mevcut kamu portalları (T.C. Bakanlık SİM portalı, OpenWeatherMap genel API'si) saatlik veri yayınlasa da bu verinin birleştirilmesi, temizlenmesi, analitik depolama biçimine dönüştürülmesi ve tarihsel trendlerle karşılaştırılması son kullanıcıya bırakılmaktadır. Ham verilerin pratikte kullanılabilir hâle gelmesi için karşılaşılan başlıca sorunlar şunlardır: (1) heterojen kaynak biçimleri (REST JSON ile cp1254 kodlu CSV); (2) eksik ve gürültülü ölçümler (sensör arızaları, kalibrasyon kaymaları, negatif değer hataları); (3) zaman dilimi tutarsızlıkları (CSV'lerde naive timestamp); (4) tarihsel ve gerçek zamanlı kanalların ayrı şemalarda tutulması nedeniyle birleşik analiz yapılamaması; (5) idempotent yeniden yükleme garantisinin olmaması nedeniyle aynı dosyanın iki kez yüklenmesi durumunda kayıt çoğalması (duplicate).

### 2B. Problem İçin Bulunan Çözüm

Bu çalışma, yukarıda sayılan sorunları otomatize biçimde çözen ve replikasyona uygun bir referans veri boru hattı ortaya çıkarmayı hedeflemektedir. Önerilen çözüm dört bağımsız katmandan oluşan bir mimaridir: (1) Veri Toplama (Ingestion); (2) İşleme (Processing); (3) Depolama (Storage); (4) Sunum (Presentation). Katmanlar arası iletişim açık kontratlar üzerinden gerçekleşir: streaming kanalı için Kafka topic şeması, batch kanalı için doğrudan PostgreSQL tablo şeması.

Çözümün üç temel mühendislik katkısı şunlardır:

1. Hibrit dağıtım deseni: Stateful streaming bileşenleri (Spark master/worker, Kafka brokeri) yerel Docker Compose üzerinde tutulurken; managed PostgreSQL, Grafana ve stateless Python uygulamaları Coolify üzerinde provision edilmektedir. Bu ayırım hem yedekleme/restore sorumluluğunu Coolify'a delege eder hem de Spark cluster'ın 2–3 GB RAM ihtiyacını yerel makineye sınırlar.
2. İdempotent ingestion: fact\_measurements tablosunda (station\_id, pollutant\_id, measured\_at, source) dörtlüsü üzerinde tanımlı UNIQUE kısıtı ile psycopg2 seviyesinde ON CONFLICT DO NOTHING kombinasyonu, aynı CSV dosyasının iki kez yüklenmesi hâlinde fazladan satır üretmeyi yapısal seviyede engellemektedir. Bu, dersin veri kalitesi konusundan önce sağlanan bir altyapı garantisidir.
3. Aylık RANGE partition + BRIN indeks kombinasyonu: Append-only zaman serisi verisi için PostgreSQL 16 üzerinde 312.000 satırlık sentetik yük altında ölçülmüş bir tasarımıdır. BRIN

indeks toplam 600 KiB yer kaplarken, eşdeğer B-tree indeks 7,00 MiB sürmektedir; oran yaklaşık 1:11,7'dir.

## 2C. Bu Alanda Yapılan Daha Önceki Çalışmaların Özeti

Hava kalitesi izleme için açık veri agregasyonu ve görselleştirilmesi konusunda olgunlaşmış birçok platform bulunmaktadır. Bu çalışmanın kapsamı doğrudan rakip bir ürün değil, dersin teorik konularını gerçek dünya verisi üzerinde sentezleyen bir referans pipeline olduğundan; aşağıdaki çalışmalar tasarım kararlarına ilham veren ve kıyas noktası oluşturan örnekler olarak değerlendirilmiştir.

- OpenAQ — Dünya genelinde 100'ün üzerinde ülkeden hava kalitesi verisi toplayan açık kaynaklı bir agregasyon platformudur. AWS S3 üzerinde Parquet formatında veri yayınlar ve REST API ile sorgu sunar. Bu çalışmadan farkı: tek bir şehre odaklanmaması, yıldız şeması yerine flat veri lake yaklaşımı kullanması ve canlı streaming yerine periyodik batch güncelleme yapmasıdır.
- IQAir AirVisual — Ticari bir platform olarak hem cihaz hem yazılım sunar; AQI hesaplamasında EPA breakpoint tablosunu referans alır. Bu çalışmada AQI hesaplama yaklaşımı (Hafta 7 sprintinde implement edilecek) doğrudan EPA'nın 2024 tarihli teknik dokümanını referans alacaktır; bu açıdan IQAir ile aynı standardı paylaşmaktadır.
- EEA Air Quality Viewer — Avrupa Çevre Ajansı'nın resmi raporlama portalıdır; 2008/50/EC direktifinin sınır değerlerini görselleştirir. Bu çalışmada dim\_pollutant tablosunda hem WHO 2021 hem EU 2008/50/EC sınır değerleri tutulmakta, böylece ileride alarm kurallarının her iki referansa göre kurulabilmesi sağlanmaktadır.
- Akademik literatürde Akidau, Chernyak ve Lax (2018) tarafından kaleme alınan Streaming Systems kitabı, watermark ve windowing kavramlarının teorik temelini verir. Bu çalışmadaki 10 dakikalık watermark ve 1 saatlik tumbling window seçimleri, söz konusu kitapta tanımlanan event-time processing modelinin doğrudan uygulamasıdır.
- Boyutsal modelleme tarafında Kimball ve Ross (2013) tarafından yazılan The Data Warehouse Toolkit kitabı, tipik OLAP iş yükü için yıldız şemasının kazançlarını belgelemektedir. Bu projedeki dim\_station, dim\_pollutant, dim\_time + fact\_measurements tasarımı doğrudan Kimball desenine uyar; tek farklılık fact tablosunun PostgreSQL 16 partition zorunluluğu nedeniyle composite primary key (measurement\_id, measured\_at) kullanmasıdır.

## Bölüm 3: Veri Seti ve Modelleme

### 3A. Projede Kullanılan Veri Setleri

Veriler iki ayrı kanaldan toplanmaktadır: (1) OpenWeatherMap Air Pollution API üzerinden gelen canlı saatlik veri, (2) T.C. Çevre, Şehircilik ve İklim Değişikliği Bakanlığı SİM portalı üzerinden indirilen tarihsel CSV dosyaları. Bu ayırım, Kimball ve Ross'un (2013) klasik veri ambarı yaklaşımındaki ilk yükleme + artımlı yükleme desenine paralel düşer; tarihsel CSV'ler ilk yüklemeyi (initial load) sağlarken, canlı API artımlı yüklemeyi (incremental load) besler.

#### 3A.1 Veri Kaynağı 1 — OpenWeatherMap Air Pollution API

| Özellik                  | Değer                                                                                                                          |
|--------------------------|--------------------------------------------------------------------------------------------------------------------------------|
| Uç nokta (endpoint)      | <a href="https://api.openweathermap.org/data/2.5/air_pollution">https://api.openweathermap.org/data/2.5/air_pollution</a>      |
| Kimlik doğrulama         | Query string parametre: appid=<API_KEY>                                                                                        |
| Birim                    | $\mu\text{g}/\text{m}^3$ (PM <sub>2.5</sub> , PM <sub>10</sub> , NO <sub>2</sub> , SO <sub>2</sub> , O <sub>3</sub> , CO için) |
| Çekim frekansı           | Saatlik (APScheduler cron, 60 dakika)                                                                                          |
| Yanıt biçimi             | JSON (pydantic ile şema doğrulaması)                                                                                           |
| Kapsanan istasyon sayısı | 6 (Konak, Bornova, Karşıyaka, Alsancak, Bayraklı, Aliğa)                                                                       |

#### 3A.2 Veri Kaynağı 2 — T.C. Çevre Bakanlığı SİM Portalı CSV

| Özellik                 | Değer                                                                |
|-------------------------|----------------------------------------------------------------------|
| Karakter kodlaması      | cp1254 (Windows Türkçe), fallback utf-8-sig                          |
| Eksik değer ifadesi     | Boş hücre veya tire (-) karakteri                                    |
| Zaman damgası           | Tarih + saat ayrı kolonlar, naive (TZ bilgisiz)                      |
| Varsayılan zaman dilimi | Europe/Istanbul (--source-timezone parametresi ile değiştirilebilir) |
| Veri çözünürlüğü        | Saatlik                                                              |
| Birim                   | $\mu\text{g}/\text{m}^3$ (SİM portalı zaten bu birimde yayınlar)     |

#### 3A.3 Veri Hacmi

6 istasyon  $\times$  6 kirletici  $\times$  saatlik çözünürlük yaklaşık 36 ölçüm/saat  $\approx$  864 ölçüm/gün  $\approx$  315.360 satır/yıl üretmektedir. Sprint 4 performans testlerinde bu hacim sentetik olarak üretilmiş ve fact tablosu tasarımı söz konusu büyüklüğe göre kalibre edilmiştir (12 ay  $\times$  30 gün  $\times$  24 saat  $\times$  6  $\times$  6 = 311.040 satır).

### 3B. Veri Toplama Aşamaları

İki farklı kaynak kanalı için iki ayrı toplama akışı tasarlanmıştır. Her ikisinin de adımları aşağıda verilmiştir.

#### 3B.1 Streaming Kanalı (Canlı API)

1. api\_collector.py modülü, APScheduler cron tetikleyicisi ile her 60 dakikada bir altı istasyonun lat/lon koordinatlarını OpenWeatherMap'in /data/2.5/air\_pollution ve /weather uç noktalarına gönderir.
2. Yanıt JSON'u pydantic modeli ile doğrulanır; şemaya uymayan alanlar erken aşamada reddedilir.
3. Doğrulanmış ölçüm, kafka\_producer.KafkaProducerWrapper.publish çağrısı ile air-quality-raw isimli Kafka topic'ine yazılır. Mesaj key'i "<station\_id>:<iso\_hour>" formatındadır; aynı saat dilimi için yapılan yeniden çekim deterministik olarak aynı partition'a düşer.
4. Hata ölçeklenmesi için tenacity kütüphanesi ile 429 ve 5xx HTTP yanıtları üzerinde exponential backoff retry uygulanır (maksimum 3 deneme). Serileştirilemeyen mesajlar ayrı bir DLQ (Dead Letter Queue) topic'ine yönlendirilir.
5. Tüm log çıktılarında API key sızıntısını engellemek için \_mask\_url fonksiyonu, query string'deki appid parametresini regex ile maskeler.

### 3B.2 Batch Kanalı (Tarihsel CSV)

1. Operatör, csv\_loader.py modülünü CLI'dan çalıştırır: python -m src.ingestion.csv\_loader <dosya.csv> --station-slug <slug>.
2. CSV önce cp1254 ile okunur; başarısız olursa utf-8-sig fallback'i devreye girer.
3. Naive timestamp, --source-timezone parametresi ile localize edilir (varsayılan Europe/Istanbul) ve ardından UTC'ye çevrilir.
4. Temizleme adımları sırayla uygulanır (forward-fill, negatif değer drop, IQR outlier filter).
5. psycpg.executemany ile 10.000 satırlık batch'ler hâlinde fact\_measurements tablosuna yazılır; ON CONFLICT ... DO NOTHING ile idempotency korunur.
6. CLI çıktı olarak (inserted, skipped) tuple'ını stderr'e basar; bu metrik test ortamında doğrulamada kullanılır.

## 3C. Veri Formatları ve Yöntemler

| Kanal                | Format                    | Yöntem                                      | Frekans                   |
|----------------------|---------------------------|---------------------------------------------|---------------------------|
| OpenWeatherMap API   | JSON (REST)               | Python httpx + APScheduler + Kafka producer | Saatlik                   |
| SiM Portalı CSV      | cp1254 CSV                | Python csv + pandas + psycpg batch insert   | Manuel/aylık              |
| İç şema (PostgreSQL) | İlişkisel + partition     | psycpg migration runner (NNNN_<slug>.sql)   | Sürüm bazlı               |
| Akış kuyruğu         | Kafka mesajı (JSON value) | Spark Structured Streaming readStream       | Sürekli (10 dk watermark) |

## 3D. Veri Ön İşleme

### 3D.1 Ön İşlemeye Neden İhtiyaç Duyulduğu

Hem canlı API hem tarihsel CSV kanalı, ham hâlleriyle analitik kullanıma hazır değildir. Üç temel sebep ön işlemeyi zorunlu kılmaktadır:

- Sensör arızaları ve kalibrasyon kaymaları nedeniyle CSV verilerinde negatif değerler veya fiziksel olarak imkânsız aşırı yüksek değerler görülmektedir. Konsantrasyon değerleri tanım gereği sıfır veya pozitif olmalıdır.
- Cihaz arızaları kısa süreli boşluklar (gap) yaratmaktadır. Bu boşlukların 3 saat ile sınırlı olanları kapatılabilir; aksi takdirde zaman serisi analizleri ve hareketli ortalamalar bozulur.
- CSV'lerde timestamp'ler naive (TZ bilgisiz) olarak gelir. Sistem genelinde UTC kullanılmadığı takdirde yaz/kış saati geçişlerinde tutarsızlıklar meydana gelir; bu durum Sprint 3 sonu Codex code review'unda C2 bulgusu olarak kayıt altına alınmıştır.


### 3D.2 Ön İşlemede Kullanılan Yöntemler

| Adım               | Kural                                                                 | Gerekçe                                                                       |
|--------------------|-----------------------------------------------------------------------|-------------------------------------------------------------------------------|
| Forward-fill       | Boşlukları en fazla 3 saat ileri doldur                               | Kısa cihaz arızalarını absorbe et; daha uzun boşluklar gerçek veri yokluğudur |
| Negatif değer drop | Konsantrasyon < 0 ise satır düşür                                     | Sensör hatası (kirletici konsantrasyonu negatif olamaz)                       |
| IQR outlier filter | $Q3 + 1.5 \cdot IQR$ üstü değerler kirletici bazında drop             | Kalibrasyon kayması veya cihaz arızası kaynaklı uç değer eleme                |
| Birim doğrulama    | Tüm değerler $\mu\text{g}/\text{m}^3$ varsayımı (varsayım belgelendi) | SİM ve OpenWeatherMap zaten $\mu\text{g}/\text{m}^3$ yayınlar                 |
| TZ normalize       | naive → Europe/Istanbul → UTC                                         | Yaz/kış saati geçişlerinde tutarlı sıralama                                   |
| Duplicate guard    | (station_id, pollutant_id, measured_at, source) UNIQUE                | Idempotent yeniden yükleme garantisi                                          |

### 3E. Kullanılan Veri Modelleri ve Veri Diyagramı

PostgreSQL 16 üzerinde klasik yıldız şeması (star schema) tercih edilmiştir. Boyut tabloları küçüktür (en büyüğü dim\_time ≈ 17.000 satır), fact tablosu yıllık ~315.000 satır oranında büyür. Tipik OLAP iş yükü (örneğin GROUP BY date\_trunc, station) için yıldız şemasının bilinen kazançlarından yararlanılmaktadır (Kimball ve Ross, 2013).

Şekil 2 — fact\_measurements Yıldız Şeması (ER Diyagramı)



Şekil 1: fact\_measurements yıldız şeması (ER diyagramı). Üç boyut tablosu (dim\_station, dim\_pollutant, dim\_time) ortak fact tablosuna 1..N ilişkisi ile bağlıdır. Fact tablosu aylık RANGE partition'lı olup primary key (measurement\_id, measured\_at) composite tanımlıdır.

### 3E.1 Boyut Tabloları (Dimension)

- dim\_station — Konak, Bornova, Karşıyaka, Alsancak, Bayraklı, Aliğa için 6 satır içerir. Aliğa endüstri profili (rafineri ve demir-çelik tesisleri) PM<sub>10</sub>, SO<sub>2</sub> ve NO<sub>x</sub> açısından diğer istasyonlardan ayrılmaktadır; bu nedenle category kolonu trafik / yerleşim / endüstri ayrımını taşır. Konum bilgileri config/stations.yaml dosyasından seed\_dim\_station.py tarafından INSERT ... ON CONFLICT (slug) DO UPDATE (UPSERT) ile yüklenir.
- dim\_pollutant — PM<sub>2.5</sub>, PM<sub>10</sub>, NO<sub>2</sub>, SO<sub>2</sub>, O<sub>3</sub>, CO için 6 seed satırı. WHO 2021 kılavuzu ve EU 2008/50/EC direktifinin sınır değerleri µg/m<sup>3</sup> cinsinden tutulmaktadır.
- dim\_time — Saatlik granülerite ile surrogate primary key time\_id = YYYYMMDDHH formatında (örneğin 2026042714 → 27 Nisan 2026 saat 14:00). 24 ay × 30 gün × 24 saat ≈ 17.000 satır kapasitelidir. is\_holiday flag'i Hafta 5 sprintinde Türkiye resmi tatil listesi ile doldurulacaktır.
- data\_quality\_runs (audit) — Hafta 12 sprintindeki Data Quality framework için iskelet açılmıştır. BIGSERIAL run\_id, JSONB payload, DELETE GRANT'i tanımlanmamış (immutable audit trail). Suite dolumu Hafta 12'de gerçekleşecektir.

### 3E.2 Fact Tablosu ve Partition Stratejisi

fact\_measurements tablosu aylık RANGE partition'lı tasarlanmıştır. Toplam 24 aylık leaf partition (2024-01 ... 2025-12) ve range dışı satırlar için bir fact\_measurements\_default catch-all partition mevcuttur. PG 16'nın partition anahtarını primary key'e dahil etme zorunluluğu nedeniyle PK (measurement\_id, measured\_at) composite olarak tanımlanmıştır. BIGSERIAL yerine açık CREATE SEQUENCE + DEFAULT nextval(...) tercih edilmiştir; bu, PG 16'da partition + identity inheritance ile ilgili bilinen bir kenar durumu kaçınmak içindir.

pg\_partman extension'ı kullanılmamıştır (Sprint 4'teki B1 mimari kararı): Coolify managed PostgreSQL'de CREATE EXTENSION yetkisi belgelenmediğinden, 24 ay scope'unda manuel CREATE TABLE ... PARTITION OF yeterli kabul edilmiştir. Bu karar Hafta 10 sprintinde yeniden değerlendirilecektir.

### 3F. Kullanılan Analizler ve Hesaplamalar

Bu raporun yazıldığı an itibarıyla (Hafta 4 sonu) tamamlanmış ve planlanmış analiz türleri aşağıda ayrıştırılmıştır.

#### 3F.1 Tamamlanmış (Sprint 1–4)

- İdempotent batch yükleme: aynı CSV dosyasının iki kez yüklenmesi durumunda tablo satır sayısının artmadığını doğrulayan integration test.
- Partition pruning ölçümü: 1 aylık tarih aralığı sorgusunda yalnızca tek bir partition'ın taranması; EXPLAIN ANALYZE çıktısı ile kanıtlanmıştır (Bölüm 4'te detaylı).
- İndeks boyut karşılaştırması: BRIN indeks 600 KiB ile B-tree composite indeks 7,00 MiB; oran 1:11,7.

#### 3F.2 Planlı (Sprint 5–7)

- Hareketli ortalama (moving average): Spark batch işi ile günlük/haftalık/aylık agregasyonlar (Hafta 6).
- İstasyonlar arası korelasyon matrisi: Pearson korelasyon ile aynı kirleticide farklı istasyonlar arası ilişki (Hafta 6).
- AQI hesaplaması: EPA breakpoint tablosu kullanılarak  $I_p = ((I_{Hi} - I_{Lo}) / (BP_{Hi} - BP_{Lo})) \times (C_p - BP_{Lo}) + I_{Lo}$  formülü; genel AQI alt indekslerin maksimumu (Hafta 7).

### 3G. Makine Öğrenmesi Yöntemleri

Makine öğrenmesi katmanı, projenin dönem sonu fazına (Hafta 14–15) bırakılmıştır. Şu aşamada herhangi bir model eğitilmemiş veya doğrulanmamıştır; dolayısıyla bu raporda sahte (fabricate) doğruluk metriği üretilmemektedir. Hafta 14–15 sprintinde aşağıdaki yaklaşım planlanmaktadır:

- Feature engineering: lag features (t-1, t-3, t-24 saat gecikmeli ölçümler), rolling statistics (3 saat ortalama, 24 saat varyans) ve dim\_time tablosunun is\_holiday, dow, season kolonları tahmin özniteliği olarak kullanılacaktır.
- Model adayları: 24 saat ileri AQI tahmini için Prophet (zamansal ayrıştırma + bayram etkileri için uygun) ve klasik ARIMA karşılaştırılacaktır.
- Değerlendirme: MAE, MAPE ve %95 güven aralığı raporlanacaktır. Hafta 4 itibarıyla veri hacminin model eğitime yetip yetmeyeceği bir risk olarak işaretlenmiştir; gerekirse SİM portalından ek tarihsel veri çekilecektir.

### 3H. Görselleştirme

Görselleştirme katmanı iki farklı kullanıcı persona'sına hizmet vermektedir: operasyonel izleme için Grafana, analitik keşif ve ad-hoc sorgu için Streamlit.

| Araç                      | Kullanım                                                                    | Durum (H4 sonu)                                                      |
|---------------------------|-----------------------------------------------------------------------------|----------------------------------------------------------------------|
| Grafana 11.x              | Anlık AQI gauge, trend zaman serisi, eşik aşım alarmları, 5 dk auto-refresh | Coolify service template ayakta; panel yapılandırması Hafta 13       |
| Streamlit 1.40+           | Tarihsel keşif, korelasyon matrisi heatmap, istasyon karşılaştırma          | Coolify üzerinde aqi-streamlit kaynak ayakta; sayfa içeriği Hafta 13 |
| Streamlit harita bileşeni | İzmir 6 istasyon konum bazlı renk kodlu AQI haritası                        | Hafta 13 (planlı)                                                    |

### 3I. Kullanılan Veritabanları

| Sistem                   | Rol                                                        | Kapasite / Notlar                                |
|--------------------------|------------------------------------------------------------|--------------------------------------------------|
| PostgreSQL 16            | Birincil OLAP veri ambarı (yıldız şeması, partition, BRIN) | Coolify managed; magic password; otomatik backup |
| Apache Kafka 3.7 (KRaft) | Streaming mesaj kuyruğu (air-quality-raw, DLQ topic)       | Yerel Docker Compose; 1 partition; Zookeeper yok |
| Yerel SQLite (test only) | testcontainers fixture'larında ephemeral test veritabanı   | Sadece unit test; production yolu yok            |

## Bölüm 4: İlerleme

### 4A. Proje Öneri Formunda Belirtilen Aşamaların Detayı

Proje öneri formunda 16 haftalık dönem dört temel sprint kategorisine ayrılmıştır: (1) Kurulum ve altyapı (Hafta 1–2), (2) Veri toplama ve şema (Hafta 3–4), (3) İşleme ve sunum (Hafta 5–13), (4) Makine öğrenmesi ve final teslim (Hafta 14–16). Aşağıdaki tablo, raporun yazıldığı an (Hafta 4 sonu, 28 Nisan 2026) itibarıyla her bir sprintin somut çıktılarını göstermektedir.

| Sprint | Tema                                     | Durum        | Önemli Çıktılar                                                              |
|--------|------------------------------------------|--------------|------------------------------------------------------------------------------|
| 1–2    | Setup + Coolify provisioning             | Tamamlandı   | 5 Coolify kaynağı canlı (DB, Grafana, Streamlit, in Kafka opsiyonel)         |
| 3      | Kafka + API + CSV loader                 | Tamamlandı   | 11/11 görev; 3 Codex review fix (C1/C2/C3); api_ ve csv_loader %96+ coverage |
| 4      | Star schema + partition + idempotency    | Tamamlandı   | 10/10 görev; sıfır finding güvenlik denetimi; parti pruning EXPLAIN kanıtı   |
| 5–7    | dim_time + Spark batch + Spark streaming | Planlı       | Hafta 5 başlangıçta; TD-05 PySpark uyumluluğu ç bekliyor                     |
| 8      | Ara rapor (%40)                          | Hazırlanıyor | Bu doküman + canlı demo                                                      |

#### 4A.1 Sprint 1–2 — Setup ve Provisioning

Hafta 1–2 boyunca proje iskeleti ayağa kaldırılmıştır. Yerel geliştirme ortamı için Docker Compose dosyası hazırlanmış; Kafka, PostgreSQL, Spark master/worker, Grafana ve Streamlit container'ları make up tek komutu ile birlikte ayağa kalkmaktadır. Coolify tarafında ise air-quality-db (PostgreSQL 16 managed), air-quality-grafana (service template), aqi-streamlit ve aqi-ingestion (public GitHub app) kaynakları provision edilmiştir. Tüm kaynaklar healthy durumdadır; ancak panel yapılandırmaları henüz yüklenmemiştir.

#### 4A.2 Sprint 3 — Veri Toplama Katmanı

Sprint 3 boyunca iki ayrı ingestion akışı kodlanmıştır: api\_collector.py ve csv\_loader.py. Sprint sonunda yapılan harici code review (Codex) üç bulgu döndürmüş ve aynı sprint içinde kapatılmıştır:

- C1: Dockerfile.ingestion config/ klasörünü COPY etmiyordu; container'da station catalog bulunmuyordu. Çözüm: DEFAULT\_STATIONS\_PATH repo-anchored hâle getirildi ve Dockerfile'a COPY direktifi eklendi (commit f22978d).
- C2: CSV naive timestamp UTC'ye yanlış localize oluyordu. Çözüm: --source-timezone parametresi eklendi (varsayılan Europe/Istanbul) ve test fixture'ları yaz saati geçişini kapsayacak şekilde genişletildi (commit 0e5e140).
- C3: init.sql içinde CREATE ROLE + ALTER ROLE PASSWORD aynı DO bloğu içinde tanımlanmıştı; psql ':'var' kuralını ihlal ediyordu. Çözüm: CREATE ve ALTER ayrı statement'lara bölündü (commit 9dfcc68).

#### 4A.3 Sprint 4 — Yıldız Şeması, Partitioning, Idempotency


Sprint 4'te veri ambarı katmanı tamamlanmıştır. 10 görevin tamamı kapatılmış, sıfır bulgu ile güvenlik denetiminden geçmiştir. Sprint kapsamında dört migration uygulanmıştır:

| Versiyon | Dosya                          | İçerik                                                                                 |
|----------|--------------------------------|----------------------------------------------------------------------------------------|
| 0001     | 0001_baseline.sql              | Hafta 3 stub: 3 dimension + flat fact + 6 satır pollutant seed                         |
| 0002     | 0002_star_schema_expand.sql    | dim_station kolon ekleme, dim_time yeni tablo, fact_measurements_unique_reading UNIQUE |
| 0003     | 0003_partition_and_indexes.sql | Partition swap (24 monthly + default), BRIN + 2x B-tree                                |
| 0004     | 0004_views_and_audit.sql       | v_hourly_aqi, v_daily_trends, data_quality_runs, GRANT'ler                             |

Her migration için \*.down.sql rollback dosyası hazırlanmıştır. Migration framework'ünde DROP TABLE ve DROP COLUMN ifadeleri reddedilmektedir; bu, geçmiş sprint verilerinin kazara silinmesini önleyen yapısal bir guardrail'dir.

## 4B. Yüksek Seviyeli Sistem Mimarisi

Şekil 1 — Yüksek Seviyeli Sistem Mimarisi



Şekil 2: Yüksek seviyeli sistem mimarisi. Streaming kanalı (üst sıra) ve batch kanalı (alt sıra) PostgreSQL fact tablosunda birleşir; sunum katmanı (Grafana ve Streamlit) bu tabloya ve onun üzerine kurulu materialize edilmiş görünüme bağlanır.

## 4C. Performans Ölçümleri (Sprint 4 DoD Doğrulaması)

Sprint 4'ün Definition of Done (DoD) kriterlerinden biri, 312.000 satırın 60 saniyenin altında batch yüklenebilmesidir. tests/integration/test\_load\_performance.py koşumu (2026-04-27 tarihinde, ASUS TUF Gaming F15 dizüstü, Intel 13. nesil 16 mantıksal core, 32 GB RAM, NVMe SSD, postgres:16.4-alpine testcontainers konfigürasyonunda) aşağıdaki sonuçları üretmiştir.

| Metrik                                     | Değer                         |
|--------------------------------------------|-------------------------------|
| Yüklenen satır                             | 311.040                       |
| Wall-clock süre                            | 52,575 saniye                 |
| Throughput                                 | ~5.916 satır/sn               |
| DoD bütçesi                                | 60 saniye                     |
| Marj                                       | 7,4 saniye (~%12 buffer)      |
| BRIN index toplam boyut                    | 600 KiB (24 partition leaf'i) |
| B-tree composite (station_id, measured_at) | 7,00 MiB                      |
| B-tree pollutant                           | 2,49 MiB                      |
| BRIN / B-tree composite oranı              | 1:11,7                        |

Partition pruning kanıtı için aşağıdaki EXPLAIN ANALYZE çıktısı, tek aylık tarih aralığı sorgusunun yalnızca ilgili partition'ı taradığını göstermektedir:

```
Aggregate (cost=786.38..786.39 rows=1 width=16) (actual time=2.696..2.697 rows=1 loops=1)
  Buffers: shared hit=268
    -> Seq Scan on fact_measurements_2024_06 fact_measurements
          (cost=0.00..656.80 rows=25916 width=8)
          (actual time=0.009..1.627 rows=25920 loops=1)
          Filter: ((measured_at >= '2024-06-01 00:00:00+00')
                    AND (measured_at < '2024-07-01 00:00:00+00'))
Planning Time: 1.673 ms
Execution Time: 2.721 ms
```

Yorum: Yalnızca fact\_measurements\_2024\_06 partition'ı taranmış, kalan 23 monthly partition ve default plana alınmamıştır. Planner Sequential Scan'ı tercih etmiştir çünkü 25.000 satır ≈ 268 sayfa boyutundadır ve B-tree seek + heap fetch maliyeti bu boyutta sequential scan'ı geçer. Bu, doğru bir karardır; partition pruning'in marjinal kazancı zaten diğer 23 partition'ı plana almamak üzerinedir.

#### 4D. Test ve Coverage Durumu

pytest --cov=src --cov=infra koşumu (2026-04-27 tarihli):

- Toplam: 234 passed + 1 skipped (Kafka broker integration testi; KAFKA\_INTEGRATION\_BOOTSTRAP env değişkeniyle opt-in)
- Unit suite: 165 passed, 13,22 saniye
- Integration suite: 69 passed, 156 saniye (testcontainers PG 16 alpine)
- Sprint 1–4 in-scope coverage: ~%96,67

Modül bazlı coverage:

| Modül                       | Coverage |
|-----------------------------|----------|
| src/ingestion/main.py       | %100,00  |
| src/config/settings.py      | %100,00  |
| src/ingestion/csv_loader.py | %97,54   |

| Modül                              | Coverage |
|------------------------------------|----------|
| src/ingestion/kafka_producer.py    | %96,58   |
| src/ingestion/api_collector.py     | %96,23   |
| infra/postgres/seed_dim_station.py | %93,10   |
| infra/migrations/run.py            | %92,07   |

Global coverage rakamı %58,55 olarak görünmektedir; bu, Coolify provisioning, Spark ve Data Quality stub modüllerinin payda olarak hesaba katılmasından kaynaklanmaktadır. Söz konusu modüller henüz implement edilmemiştir (%0). Sprint kapsamına girmiş kodda ölçülen %96,67 in-scope coverage daha anlamlı bir göstergedir.

#### 4E. Karşılaşılan Problemler ve Çözümler

Sprint 1–4 boyunca karşılaşılan ve çözülen başlıca mühendislik problemleri aşağıdaki tabloda özetlenmiştir. Her satır gerçek bir blocker veya ret kriterini temsil eder; tech-debt envanterindeki (tech-debt.md) ilgili madde referans olarak verilmiştir.

| Problem                                                                                                                                                                             | Çözüm                                                                                                                                                               | Referans                          |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------|
| PG 16 partitioned PK kuralı: ALTER TABLE ... ADD PRIMARY KEY (measurement_id) reddedildi; PG 16 partition anahtarını PK'ya dahil etmeyi zorunlu kılıyor.                            | PK (measurement_id, measured_at) composite olarak yeniden tanımlandı; FK referansları otomatik partition seçimini bozmuyor.                                         | sprint-04 T3                      |
| Constraint adı çıkışması partition swap'ında: yeni fact_measurements_partitioned ile eski tabloyu RENAME ile takas ederken FK ve UNIQUE constraint adları çıkışıyordu.              | Eski tablonun constraint adlarına _legacy_* prefix taşındı (kalıcı silme yerine), sonra DROP TABLE _legacy_*; rollback path için *.down.sql sembolik.               | sprint-04 T3                      |
| testcontainers Docker-in-Docker maliyeti: integration testler GitHub Actions runner'ında her CI koşulunda +60–90 sn ekliyordu.                                                      | @pytest.mark.integration marker ile ayrıştırıldı; make test default'ta filter'lı, make test-integration opt-in target.                                              | TD-12                             |
| PostgreSQL functional dependency hatası (matview): Sprint 4 T6'da v_hourly_aqi tanımında GROUP BY listesinde eksik kolon nedeniyle CREATE patladı; static analiz/lint yakalayamadı. | Integration test (testcontainers) bug'ı CI öncesi yakaladı; static testin yetmediği bir vaka olarak belgelendi.                                                     | sprint-04 T6                      |
| Coolify managed PG extension yetkisi belirsizliği: pg_partman tercih edilseydi CREATE EXTENSION yetkisi gerekecekti; bu yetki belgelenmemiş.                                        | Manuel CREATE TABLE ... PARTITION OF 24 ay scope'unda yeterli kabul edildi (B1 mimari kararı); pg_partman değerlendirmesi Hafta 10'a TD-candidate olarak ertelendi. | sprint-04 B1                      |
| Codex external review fix'leri (C1/C2/C3): config klasörü COPY edilmiyordu; CSV naive timestamp yanlış localize oluyordu; init.sql DO block içinde psql :var kuralı ihlali.         | C1: DEFAULT_STATIONS_PATH repo-anchored + COPY eklendi. C2: --source-timezone parametresi eklendi. C3: CREATE/ALTER ayrıldı.                                        | Commits f22978d, 0e5e140, 9dfcc68 |

| Problem                                                                                                                                                              | Çözüm                                                                                                    | Referans |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------|----------|
| httpx access log policy: Default httpx.AsyncClient access log emit etmez ama 3rd-party middleware (örn. opentelemetry-httpx) eklenirse appid query string sızabilir. | CLAUDE.md'ye 3 cümlelik policy paragrafı eklendi (TD-07); _mask_url zaten contract test'lerle korunuyor. | TD-07    |

#### 4F. Çözilemeyen Problemler ve Planlanan Yaklaşımlar

Aşağıdaki problemler Hafta 4 sonu itibarıyla aktif hâtedir; bunlar için somut çözüm planları ilgili sprintlere atanmıştır.

- TD-05 — PySpark 3.5.1 + Python 3.13 wheel uyumsuzluğu: Yerel .venv Python 3.13.7'de PyPI'da cp313 wheel yoktur; yalnızca sdist (317 MB) bulunmaktadır. pip install -e "[processing]" build aşamasında dakikalarca asılı kalmaktadır. Sprint 3'te [processing] extra atlanmıştır. Hafta 6 spark-engineer kickoff'unda üç seçenek karşılaştırılacaktır: (a) venv'i Python 3.11/3.12'ye düşürme, (b) pyspark pin'ini 3.5.4+'a yükseltme, (c) yalnızca Docker bitnami imajı üzerinden çalışma. Riski: Hafta 6 başında karar verilemezse Spark batch sprintinin 1–2 gün gecikmesi mümkün.
- TD-15 — Coolify managed PostgreSQL'de migration deploy hook eksikliği: Coolify managed PG'deki fact\_measurements row count şu an 0'dır; migration zinciri henüz Coolify'a apply edilmemiştir. Hafta 6 Spark batch ingestion'ından önce manuel psql apply veya make migrate deploy hook'u tamamlanacaktır. Hafta 10 sprintinde DevOps güçlendirme kapsamında otomatize edilecektir.
- Demo görsel eksikliği: Bu rapor draft'ında demo videosu ve gerçek Coolify ekran görüntüleri henüz eklenmemiştir. H8 final teslim öncesinde docs/images/h8/ altında watermark'lı ekran görüntüleri (gerçek Coolify URL'i blur'lı) ve 12 dakikalık demo video bağlantısı eklenecektir.
- Grafana panel/datasource yapılandırması: Coolify üzerinde Grafana service template ayağa kalktı, ancak panel ve datasource yapılandırması Hafta 13 sprintine bırakılmıştır. Bu, bilinçli bir önceliklendirmedir; veri katmanı dolmadan paneller anlamlı veri gösteremezdi.


## Bölüm 5: Sonraki Aşamalar

### 5A. Dönem Sonuna Kadar Yapılacak İşlemler

Aşağıdaki tablo, docs/PROJE\_PLANI.md belgesinde tanımlı 16 haftalık planın Hafta 4 sonu durumuyla revize edilmiş hâlidir. Sprint 1–4 tamamlandığından, Sprint 5'ten itibaren plan günceldir.

| Hafta | Tema                                           | Çıktı                                                                            | Ana Risk                            |
|-------|------------------------------------------------|----------------------------------------------------------------------------------|-------------------------------------|
| 5     | dim_time ince ayar + indeks tuning             | is_holiday seed (TR resmi tatil), random_page_cost tune                          | TR tatil kaynağı seçimi             |
| 6     | Spark batch                                    | spark_batch.py, hareketli ortalama, korelasyon matrisi                           | TD-05 PySpark uyumluluğu            |
| 7     | Spark Structured Streaming + AQI               | spark_streaming.py, aqi_calculator.py, watermark                                 | Checkpoint state yönetimi           |
| 8     | Ara rapor (%40)                                | Bu doküman + canlı demo                                                          | Demo ortamı reproducibility         |
| 9     | Streaming optimizasyonu                        | Late data, exactly-once semantics, backpressure                                  | Kafka offset yönetimi               |
| 10    | Docker Compose paketleme + Coolify deploy hook | make migrate deploy hook (TD-15), pg_partman değerlendirmesi                     | Coolify managed PG yetkileri        |
| 11    | KVKK + güvenlik gate                           | DPIA dokümanı, token rotation runbook (TD-06), DLQ ACL (TD-08)                   | KVKK formal şablonu                 |
| 12    | DQ framework                                   | Great Expectations / pydantic suite, data_quality_runs schema validation (TD-14) | Suite kapsam genişliği              |
| 13    | Görselleştirme                                 | Grafana panelleri (gauge / time series / map), Streamlit sayfaları               | Grafana FQDN port routing (TD-01)   |
| 14–15 | ML feature engineering + tahmin                | Lag features, rolling stats, Prophet/ARIMA 24h forecast                          | Veri hacmi yetersizliği             |
| 16    | Final raporu (%60)                             | Tamamlanmış proje + final rapor                                                  | Literature review + benchmark scope |

### 5B. Plan Görseli



Şekil 3: 16 haftalık proje planı, Hafta 4 sonu konumu (kesik kırmızı çizgi) ve sprint durum dağılımı. Yeşil sprintler tamamlanmış, sarı sprintler yakın planda, kırmızı sprintler teslim milestone'larıdır.

## 5C. Hafta 8 Final Teslim Öncesi Tamamlanacak Maddeler

Bu rapor draft'ı 27 Nisan 2026 itibarıyla hazırlanmıştır. Hafta 8 final teslim öncesinde aşağıdaki maddeler eklenecektir:

- docs/images/h8/ altında watermark'lı ekran görüntüleri: Coolify provisioning panel görüntüleri, make migrate çıktısı, EXPLAIN ANALYZE terminal output, pytest yeşil suite, partition listesi (d+ fact\_measurements çıktısı)
- 12 dakikalık demo video bağlantısı (gerçek Coolify URL'i blur'lı)
- Hafta 5–7 sprintleri tamamlandıktan sonra: AQI hesaplama gerçek formülünün koşturulmuş örneği ile, Spark streaming gerçek metrikleriyle (latency, throughput) ilgili bölümler güncellenecek; "Hafta X'te tamamlanacak" notları silinecektir.
- Final teslim sonrası docs/RAPOR\_H16.md belgesine literatür incelemesi (OpenAQ, IQAir, BreezoMeter karşılaştırması) ve ML sonuçları (MAE, MAPE, güven aralığı) bölümleri taşınacaktır.

## 5D. Risk Yönetimi

| Risk                                                 | Etki                                      | Azaltma Stratejisi                                                                              |
|------------------------------------------------------|-------------------------------------------|-------------------------------------------------------------------------------------------------|
| TD-05 PySpark uyumluluğu Hafta 6 başında çözülemezse | Yüksek (Spark sprintleri 1–2 gün gecikir) | Hafta 5 sonunda 3 alternatif (Python 3.11 venv / pin yükseltme / Docker-only) sırayla denenecek |
| TR resmi tatil kaynağı seçimi                        | Düşük (alternatif statik liste hazır)     | Eğer API bulunamazsa, T.C. Resmi Gazete kaynaklı statik YAML kullanılacak                       |
| Veri hacmi ML için yetersiz                          | Orta (model güveni düşer)                 | Hafta 13'te SİM portalından ek tarihsel veri çekimi planlandı (geriye 24 ay)                    |

| Risk                                           | Etki                                     | Azaltma Stratejisi                                                                         |
|------------------------------------------------|------------------------------------------|--------------------------------------------------------------------------------------------|
| Coolify Managed PG'de pg_partman yetkisi yoksa | Düşük (manuel partition zaten çalışıyor) | B1 kararı ile manuel DDL 24 ay scope'unda yeterli; Hafta 10'da yeniden değerlendirilecek   |
| KVKK formal şablonu eksikliği                  | Orta (compliance gate Hafta 11)          | Anonimleşmiş hava kalitesi verisi kişisel veri içermez; DPIA dokümanı yine de hazırlanacak |

## Kaynakça

Aşağıdaki kaynaklar bu raporda atıfta bulunulan birincil teknik ve düzenleyici dokümanlardır. Tarih biçimi APA 7 stiline yakın tutulmuştur.

- Akidau, T., Chernyak, S. ve Lax, R. (2018). Streaming Systems: The What, Where, When, and How of Large-Scale Data Processing. O'Reilly Media.
- Apache Software Foundation. (2024). Apache Kafka 3.7 Documentation — KRaft mode, producer semantics. <https://kafka.apache.org/37/documentation/>
- Apache Software Foundation. (2024). Apache Spark Structured Streaming Programming Guide (3.5). <https://spark.apache.org/docs/3.5.1/structured-streaming-programming-guide.html>
- Avrupa Birliği. (2008). Directive 2008/50/EC of the European Parliament and of the Council of 21 May 2008 on Ambient Air Quality and Cleaner Air for Europe. Official Journal of the European Union, L 152, 1–44.
- DSÖ — Dünya Sağlık Örgütü. (2021). WHO Global Air Quality Guidelines: Particulate Matter, Ozone, Nitrogen Dioxide, Sulfur Dioxide and Carbon Monoxide. Cenevre: Dünya Sağlık Örgütü.
- EEA — European Environment Agency. (2023). Air Quality in Europe — 2023 Report (EEA Report No 04/2023). Publications Office of the European Union.
- EPA — U.S. Environmental Protection Agency. (2024). Technical Assistance Document for the Reporting of Daily Air Quality — The Air Quality Index (AQI) (EPA-454/B-24-002). Office of Air Quality Planning and Standards.
- Kimball, R. ve Ross, M. (2013). The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling (3. baskı). Wiley.
- OpenWeatherMap. (2024). Air Pollution API Documentation. <https://openweathermap.org/api/air-pollution>
- PostgreSQL Global Development Group. (2024). PostgreSQL 16 Documentation — Chapter 5.11 Table Partitioning ve Chapter 11.1.7 BRIN Indexes. <https://www.postgresql.org/docs/16/>
- T.C. Çevre, Şehircilik ve İklim Değişikliği Bakanlığı. (2024). Sürekli İzleme Sistemi (SİM) Açık Veri Portalı. <https://sim.csb.gov.tr/>